

За пределами OOF: Стратегия Feature Engineering для улучшения предсказаний IC50, CC50 и SI в условиях малых химических наборов данных

Деконструкция Успешной Стратегии ChemiAI: Принципы и Ограничения

Успех команды ChemiAI, продемонстрировавшей финальный результат на уровне 272.17 RMSE, представляет собой не просто набор технических решений, а целостную стратегию, выработанную через многочисленные эксперименты и отказ от распространенных практик машинного обучения ввиду специфики хемоинформатической задачи с малым объемом данных [2](#). Анализ их пайплайна и закрытых экспериментов позволяет выявить фундаментальные принципы, которые определяют успех на данном конкурсе, а также указывает на потенциальные направления для дальнейшего улучшения. Ключевая особенность задачи заключается в малом размере обучающей выборки (751 объект), наличии нескольких таргетов (IC50, CC50, SI), которые связаны физическим инвариантом $SI \approx CC50 / IC50$, и необходимости соблюдения правил честного инжиниринга признаков, исключающих использование информации из тестового набора данных [1](#) [121](#).

Основой пайплайна является концепция простоты над сложностью. Команда активно отказалась от использования метамоделей или стекинга, где модель второго уровня обучалась бы на предсказаниях базовых моделей [125](#). Эксперимент №1, направленный на создание такого стека с использованием Ridge-регрессора, показал результат 317.29 RMSE, что было значительно хуже базовых решений [83](#). Это подтверждает общее правило для малых выборок: сложные архитектуры склонны к переобучению, особенно когда базовые модели сильно коррелированы [105107](#). Вместо этого была выбрана более простая и

стабильная стратегия — блендинг (усреднение) предсказаний отдельных специализированных моделей, каждая из которых обучена для своего таргета или блока признаков, с заранее зафиксированными весами [121](#). Такой подход, хотя и кажется интуитивно простым, в контексте данной задачи оказался значительно эффективнее, поскольку он снижает риск переобучения и повышает стабильность модели на невиданных ранее данных [127](#).

Центральным элементом стратегии является каскадная архитектура для предсказания IC50, состоящая из серии «голов» — отдельных CatBoost-моделей, каждая из которых обучается на своем блоке признаков [77](#). Этот подход основан на гипотезе, что разные группы дескрипторов кодируют разную информацию о молекуле. Процесс выглядит следующим образом: начинается с базовой модели, затем добавляется голова на функциональных группах (fr_*), за ней — на Mordred-дескрипторах, затем на Morgan-фингерпринтах и, наконец, финальная голова на всех 192 признаках [120183](#). Веса этих голов были эмпирически подобраны: `ic65_base` (базовый уровень) → `fr42` (вес 0.42) → `mordred_w55` (вес 0.55) → `morgan_w25` (вес 0.25) → `full_catboost_w25` (вес 0.25) [129](#). Такая последовательность позволила систематически накапливать сигнал, добавляя все более комплексные представления о структуре молекулы. Однако этот же процесс выявил и ограничение: насыщение сигнала. Например, попытки увеличить вес Mordred-головы выше 0.55 или веса Morgan-головы выше 0.25 не приводили к улучшению результата на Public Leaderboard, демонстрируя, что после определенного порога модель начинает переобучаться на шум, содержащийся в соответствующих блоках признаков [172190](#).

Особенно важным и контринтуитивным выводом является отказ от прямого моделирования Selectivity Index (SI). Изначальная идея использовать физический инвариант $SI = CC50 / IC50$ как жёсткое правило для тестовой выборки показала себя катастрофически (результат 360.14 RMSE) [83](#). Причина в том, что ошибка в знаменателе (IC50) может экспоненциально раздуть значение SI, делая его крайне чувствительным к ошибкам в предсказании IC50 [125](#). Вместо этого была внедрена концепция «мягкого» физического инварианта. Финальное предсказание SI получается путем взвешенной суммы двух компонент: прямого предсказания от специализированной модели (`HistGradientBoostingRegressor` с абсолютной ошибкой) и расчетного значения $CC50 / IC50$. Эти два компонента смешиваются с весом $\alpha=0.35$ для прямого предсказания и $(1-\alpha)=0.65$ для расчетного значения [29](#) [33](#). Этот подход оказался значительно стабильнее, так как он сохраняет связь с физикой, но одновременно сглаживает экстремальные значения, возникающие из-за ошибок

в предсказаниях IC50 или CC50. Это подчеркивает, что на малых выборках необходимо сочетать физические знания с осторожным подходом к моделированию зависимостей.

Наконец, важным аспектом, обеспечивающим согласованность данных, является использование трансдуктивного подхода. Для препроцессинга (импутация пропусков, масштабирование, PCA) модели обучались на объединенном наборе данных, включающем как тренировочные, так и тестовые примеры [101](#).

Критически важно, что целевые переменные тестового набора никогда не использовались в этом процессе, что полностью соответствует правилам Kaggle и минимизирует риск утечки данных [111](#). Это позволило создать единое, согласованное пространство признаков для обеих выборок, что особенно важно для таких методов, как KNN, используемых для предсказания CC50 [77](#).

Таким образом, успешная стратегия ChemiAI — это результат многократных экспериментов и отказа от распространенных практик машинного обучения из-за специфики данных. Анализ их пайплайна и закрытых экспериментов предоставляет бесценную информацию о том, чего не делать. Наиболее важный инсайт заключается в том, что высокий OOF-рейтинг не гарантирует успеха на Public Leaderboard. Многие эксперименты показали, что локальная валидация может быть крайне неточной метрикой для отбора гипотез. Например, увеличение веса Mordred-головы до $w > 0.55$ улучшило OOF, но ухудшило Public LB [129](#). То же самое произошло с pIC50-трансформацией (Эксперимент #8) и SEED-ансамблями (Эксперимент #9) [126](#). Это указывает на то, что победа достаётся не тем, кто лучше «подогнал» модель под CV, а тем, кто нашёл более стабильную и обобщающую стратегию. Этот факт должен стать отправной точкой для любых дальнейших улучшений, требуя осторожного подхода к интерпретации OOF и, при необходимости, использования Public LB для окончательной оценки гипотез.

Генерация Честных Признаков на Основе Взаимодействия Групп Дескрипторов

Несмотря на то, что пайплайн ChemiAI уже использует 192 признака, полученных из RDKit, существует значительный потенциал для улучшения за счет создания новых, синтетических признаков. Эти признаки должны быть

сгенерированы честно, то есть исключительно на основе имеющихся числовых дескрипторов без использования информации о таргетах или тестовых данных [70](#). Наибольший эффект следует ожидать от создания признаков, которые моделируют взаимосвязи между различными классами молекулярных свойств, поскольку они могут нести более глубокую, чем любой отдельный дескриптор, информацию о биологической активности и токсичности.

Наиболее перспективное направление — это создание признаков, отражающих баланс между полярностью и липофильностью, так как именно этот баланс определяет ключевые фармакокинетические свойства, такие как растворимость и проницаемость клеточных мембран, напрямую влияющие на IC50 и CC50 [45](#) [47](#). Существующие дескрипторы позволяют количественно оценить эти свойства:

- Липофильность: `MolLogP` (расчетный коэффициент разделения октанол/вода) является стандартным индикатором гидрофобности.
- Полярность: `TPSA` (топологическая полярная поверхность площадь) — это 2D-дескриптор, который быстро вычисляется и хорошо коррелирует с полярной поверхностью, играя ключевую роль в прогнозировании проницаемости мембран [46](#) [49](#).
- Топология: Топологические индексы, такие как `Chi0`, `Chi1`, `Kappa1`, `Kappa2`, описывают форму и связность молекулярного графа [1](#).

На основе этих дескрипторов можно сгенерировать следующие синтетические признаки:

Новый признак	Формула	Физическая/Химическая интерпретация
Логарифмическое соотношение липофильности к полярной поверхности	$\text{MolLogP} / (\text{TPSA} + 1e-6)$	Прямой индикатор баланса гидрофобных и гидрофильных свойств. Высокие значения указывают на более гидрофобную молекулу, что может способствовать проникновению через липидные мембраны, но ухудшать водную растворимость 47 48 .
Соотношение полярной поверхности к молекулярной массе	$\text{TPSA} / \text{MolWt}$	Аналог удельной полярной поверхности. Помогает сравнить полярность молекул разного размера. Высокое значение часто связано с хорошей растворимостью, но плохой проницаемостью 49 .
Соотношение топологии к липофильности	$\text{Chi0} / (\text{MolLogP} + 1e-6)$	Может служить индикатором простой связности молекулы в зависимости от ее гидрофобности. Полезно для QSAR-моделей, исследующих влияние формы на активность 1 .

Другое важное направление — это моделирование взаимосвязи между структурной сложностью и другими свойствами. Сложность молекулы влияет на ее свободную энергию и способность к связыванию с белками. Существующие

дескрипторы, такие как BertzCT, BalabanJ, RingCount и NumRotatableBonds, позволяют оценить эту сложность [1](#).

Новый признак	Формула	Физическая/Химическая интерпретация
Индекс сложности к полярности	$(\text{BertzCT} + \text{BalabanJ}) / (\text{TPSA} + 1e-6)$	Индикатор "сложности" молекулы относительно ее полярности. Высокое значение может указывать на сложноструктурированные, но полярные молекулы, что интересно для QSAR-моделей 25 161 .
Соотношение гибкости к стерическому объему	$(\text{NumRotatableBonds} + 1e-6) / (\text{LabuteASA} + 1e-6)$	Соотношение числа вращающихся связей (индекс подвижности) к неполярной поверхности (объем). Может быть связано с фармакокинетическими свойствами, такими как скорость метаболизма или способность к связыванию с белком 1 .
Соотношение sp ³ -гибридизации к полярности	$\text{FractionCSP3} / (\text{TPSA} + 1e-6)$	Отражает долю sp ³ -гибридизированных углеродов (индикатор насыщенности и трехмерности) относительно полярной поверхности. Высокое значение часто связано с лучшей биодоступностью 159 .

Наконец, можно создавать признаки, отражающие электронную структуру в контексте топологии. Электронные эффекты, такие как распределение частичных зарядов, критически важны для понимания механизмов связывания и реакционной способности.

Новый признак	Формула	Физическая/Химическая интерпретация
Индекс распределения заряда	$(\text{MaxAbsPartialCharge} - \text{MinAbsPartialCharge}) / (\text{MaxEStateIndex} - \text{MinEStateIndex} + 1e-6)$	Мера неравномерности распределения электронной плотности по молекуле. Высокое значение указывает на наличие выраженных электроноакцепторных и электронодных участков, что напрямую влияет на силу и специфичность связывания с мишенью 25 161 .
Отношение топологической сложности к электронной поляризуемости	$\text{Кappa3} / (\text{PEOE_VSA_POL} + 1e-6)$	Связывает топологическую сложность (Кappa3) с полярной составляющей поверхностных дескрипторов (PEOE_VSA_POL). Может помочь в моделях, предсказывающих взаимодействия, зависящие от поляризуемости 1 .

Все эти признаки являются честными, так как они создаются только из входных данных. Их добавление в пайплайн должно происходить аккуратно, в первую очередь в те блоки, которые наиболее релевантны их семантике. Например, признаки, сочетающие топологию и полярность, логично добавлять в блок Mordred или в полный набор признаков для финальной модели. Признаки, связанные с функциональными группами, могли бы дополнить блок fr_*. Важно отметить, что перед добавлением этих признаков их распределение следует проанализировать на предмет нормальности (например, с помощью логарифмического преобразования log1p), так как это может улучшить работу многих алгоритмов машинного обучения, особенно линейных и деревьев решений [151](#). Создание таких комплексных признаков позволяет модели

"думать" не только о каждом свойстве молекулы в отдельности, но и о соотношении этих свойств, что является шагом к более глубокому пониманию QSAR (количественной структурно-активной связи) [40](#) [79](#).

Нелинейные Преобразования и Бинаризация: Усиление Сигнала в Табличных Данных

Помимо создания синтетических признаков через комбинацию существующих, еще одним мощным инструментом честного инжиниринга признаков является применение нелинейных преобразований и бинаризации. Цель этих методов — сделать распределение данных более подходящим для моделей, улучшить устойчивость к выбросам и ввести в модель явные пороговые эффекты, характерные для химических систем. Эти техники особенно актуальны для малых наборов данных, где модель может плохо обобщать нелинейные зависимости, заложенные в исходных признаках [105](#).

Первый и наиболее очевидный подход — это логарифмические и степенные преобразования. В предоставленном коде видно, что для таргетов **CC50** и **SI** используется `log1p` при обучении, что является стандартной практикой для работы с данными, имеющими тяжелые правые хвосты [2](#). Аналогичный подход можно применить и к некоторым признакам. Многие молекулярные дескрипторы, такие как **MolWt** (молекулярная масса), **MolLogP** (коэффициент распределения) и различные топологические индексы (**Chi**_{em}, **Kappa**_{em}), могут иметь очень широкий диапазон значений, что может затруднять обучение моделей. Логарифмическое преобразование, такое как `np.log1p(feature)`, может сжать этот диапазон, сделав распределение более нормальным и сбалансированным. Это может улучшить производительность как линейных моделей, так и моделей на основе деревьев, которые работают с разбиениями признаков. Например, можно сгенерировать новые признаки:

- ``log1p_MolWt`: `np.log1p(MolWt)``
- ``log1p_MolLogP`: `np.log1p(MolLogP)``
- ``log1p_Chi0`: `np.log1p(Chi0)``
- ``log1p_BertzCT`: `np.log1p(BertzCT)``

Применение таких преобразований может помочь модели лучше уловить экспоненциальные зависимости, которые часто встречаются в QSAR-моделях.

Например, изменение логарифма концентрации (что эквивалентно pIC_{50}) имеет линейную зависимость с вероятностью связывания, поэтому работа с логарифмическими масштабами часто более естественна для биохимических данных [217218](#).

Второй мощный метод — это бинаризация непрерывных признаков. Этот подход основан на физической интуиции и известных правилах, таких как правило "пяти", которое помогает оценить "лечебность" молекулы [159](#). Бинаризация заключается в преобразовании непрерывного признака в двоичный (0 или 1) на основе заданного порога. Это позволяет модели явно учесть наличие или отсутствие определенного свойства. Например, можно создать бинарные признаки, сигнализирующие о соответствии молекулы критериям, которые часто используются в раннем этапе разработки лекарств:

- Бинаризованные признаки по правилу "Липински":
- ``RuleOfFive_Weight`: `(MolWt < 500).astype(int)`` [45](#)
- ``RuleOfFive_LogP`: `(MolLogP < 5).astype(int)`` [45](#)
- ``RuleOfFive_HDonors`: `(NumHDonors < 5).astype(int)`` (если доступны NumHDonors, иначе использовать ``TPSA / 22.4`` как грубую оценку)
- ``RuleOfFive_HAcceptors`: `(NumHAcceptors < 10).astype(int)`` (аналогично H-донорам)
- Бинаризация других ключевых признаков:
- ``High_TPSA`: `(TPSA > threshold).astype(int)``. Выбор порога (например, 140 Å²) может быть информативным, так как молекулы с очень высокой TPSA часто имеют проблемы с проницаемостью [49](#).
- ``High_FractionCSP3`: `(FractionCSP3 > 0.35).astype(int)``. Молекулы с высокой долей sp³-углерода часто обладают лучшими ADME-свойствами [159](#).
- ``Low_RingCount`: `(RingCount == 0).astype(int)``. Отделение алициклических соединений от ароматических.

Эти бинарные признаки могут быть особенно полезны для моделей на основе деревьев, таких как CatBoost, поскольку они легко находят оптимальные пороги для разбиения. Например, если модель видит, что все молекулы с `RuleOfFive_Weight=0` (молекулярная масса ≥ 500) имеют очень высокое значение CC_{50} , она сможет использовать этот признак для очень точного предсказания.

Кроме того, можно рассмотреть бинаризацию признаков, представляющих собой отношения. Например, можно создать бинарный признак на основе нового синтетического признака `LogP_to_TPSA_ratio`, который мы предлагали ранее: `(LogP_to_TPSA_ratio > logp_tpsa_threshold).astype(int)`. Это позволит модели отделить молекулы с доминирующими гидрофобными свойствами от гидрофильных.

Важно отметить, что эти методы должны применяться осмысленно, с опорой на научную литературу и физическую интуицию, а не механически [56](#). Например, выбор порогов для бинаризации может быть основан на анализе распределения признаков в данных или на рекомендациях из области химической информатики [45](#). После генерации этих новых признаков их следует добавить в соответствующие блоки дескрипторов в пайплайне. Например, новые логарифмические признаки могут быть добавлены в блок `full_catboost`, а бинарные признаки, основанные на правилах, могут быть добавлены в блок `fr_only` или создать новый, отдельный блок, который будет подаваться на вход одной из "голов". Эти две стратегии — нелинейные преобразования и бинаризация — являются относительно недорогими в вычислительном плане, но могут принести значительный прирост качества модели, делая ее более устойчивой к выбросам и лучше учитывающей известные биохимические закономерности.

Интеграция Новых Признаков в Архитектуру "Голов" и Исследование Альтернативных Моделей

Успешное внедрение новых признаков и рассмотрение альтернативных моделей является ключевым шагом для достижения лучших результатов. Предлагаемые новые признаки и модели должны быть интегрированы в существующую, хорошо отлаженную архитектуру пайплайна ChemiAI, которая состоит из специализированных «голов» для разных таргетов и блоков признаков. Одновременно необходимо оценить потенциал других алгоритмов машинного обучения, которые могут показать себя лучше на данной задаче.

Интеграция новых признаков должна быть таргетно-ориентированной. Вместо того чтобы просто добавлять все новые признаки в один большой набор, их

следует размещать в блоках, наиболее релевантных их семантике, чтобы каждый "head" продолжал специализироваться на своей области.

Тип нового признака	Рекомендуемый блок для интеграции	Обоснование
Синтетические признаки (соотношения) LogP_to_TPSA_ratio Complexity_to_Polarity_Index Charge_Distribution_Index	mordred или full_catboost	Эти признаки являются сложными, непрерывными и описывают комплексные свойства молекулы. Модель, обученная на большом количестве Mordred-дескрипторов, вероятно, сможет найти нелинейные зависимости между этими комплексными признаками и целевыми переменными. Добавление их в полный набор также позволяет всему пайплайну воспользоваться этим новым сигналом.
Логарифмические преобразования log1p_MolWt log1p_MolLogP log1p_BertzCT	full_catboost	Эти признаки являются модификациями существующих и полезны для всей системы. Они несут информацию о распределении данных и помогают моделям лучше справляться с широким диапазоном значений.
Бинарные признаки (правила) RuleOfFive_Weight RuleOfFive_LogP High_TPSA High_FractionCSP3	fr_only или новый блок	Эти признаки отражают выполнение или невыполнение простых, но важных правил. Они могут быть логично отнесены к блоку fr_* , который уже содержит информацию о наличии функциональных групп. Альтернативно, можно создать отдельный блок из этих бинарных признаков и подать его на вход одной из "голов" для усиления сигнала о "drug-likeness".

После интеграции новых признаков основной задачей становится перебалансировка весов в каскаде "голов" для IC50. Поскольку новые признаки могут изменить "ценность" каждого блока, оптимальные веса, найденные ранее (например, $w_{\text{mordred}}=0.55$, $w_{\text{morgan}}=0.25$), могут больше не быть наилучшими [129](#). Необходимо будет провести серию экспериментов, варьируя веса и оценивая результат на Public Leaderboard, так как локальная OOF-метрика в данном случае показала свою нестабильность и низкую корреляцию с финальным результатом [125](#). Например, если новый признак **LogP_to_TPSA_ratio** окажется очень предсказательным, возможно, стоит временно увеличить вес головы, которая его использует, и уменьшить веса других голов, чтобы найти новый, более эффективный баланс.

Параллельно с улучшением существующего пайплайна, необходимо исследовать альтернативные модели. Хотя CatBoost зарекомендовал себя как очень сильный инструмент для табличных данных, особенно благодаря своей устойчивости к переобучению и хорошей работе с категориальными данными [77](#) [187](#), другие алгоритмы градиентного бустинга могут предложить свои преимущества.

Модель	Преимущества	Недостатки	Рекомендация по применению
LightGBM	Часто работает быстрее CatBoost, особенно на больших данных. Может давать схожий или лучший результат на некоторых задачах. Хорошо справляется с разреженными данными.	Может быть более склонен к переобучению на малых и очень сбалансированных наборах данных по сравнению с CatBoost. Требуется внимательной настройки гиперпараметров (например, <code>force_col_wise=True</code>).	Заменить CatBoost в одной из "голов" (например, в <code>full_catboost</code>) на LightGBM и сравнить результаты. Это позволит оценить, является ли преимущество CatBoost в данной задаче или же это специфика реализации.
XGBoost	Очень зрелый и хорошо документированный алгоритм. Широко используется и хорошо изучен. Может давать отличные результаты при правильной настройке.	Требуется более тщательной настройки гиперпараметров по сравнению с CatBoost. Может быть медленнее LightGBM.	Провести аналогичный эксперимент, заменив CatBoost на XGBoost. Сравнение результатов трех моделей (CatBoost, LightGBM, XGBoost) поможет определить, какой алгоритм градиентного бустинга лучше всего подходит для данной конкретной задачи.
Random Forest / Extra Trees	Очень устойчивы к переобучению, не требуют тонкой настройки гиперпараметров. Обеспечивают естественную меру важности признаков.	Как правило, дают несколько более низкий базовый уровень производительности по сравнению с градиентным бустингом на той же вычислительной мощности.	Использовать как baseline или для анализа важности признаков. Можно сравнить важность признаков, полученную от CatBoost и от Random Forest, чтобы убедиться в стабильности выводов о самых информативных дескрипторах 108 .

Наконец, стоит рассмотреть более сложные подходы, такие как графовые нейронные сети (Graph Neural Networks, GNNs). GNNs представляют собой передовой класс моделей, которые работают непосредственно с графовым представлением молекулы (атомы как узлы, связи как ребра), что позволяет им автоматически извлекать сложные структурные паттерны [3](#) [56](#). Это может быть мощнее, чем использование предварительно вычисленных 2D-дескрипторов. Однако для задачи с малым объемом данных (750 примеров) GNNs несут в себе высокий риск переобучения и могут потребовать значительных вычислительных ресурсов (GPU) и экспертов для настройки [15](#). Поэтому их следует рассматривать как следующий, более продвинутый этап исследования, который нужно предпринять только после того, как будет получена максимальная отдача от табличного подхода. Также стоит отметить, что некоторые передовые подходы используют transfer learning, что значительно снижает потребность в инженерии признаков и особенно полезно для малых или несбалансированных наборов данных [24](#) [147](#).

Стратегический План Экспериментов для Улучшения Результатов

На основе проведенного анализа можно сформулировать четкий, поэтапный план действий для проведения экспериментов, направленных на улучшение текущего результата в 272.17 RMSE. Этот план учитывает ограниченность данных, нестабильность OOF-метрик и необходимость честного инжиниринга признаков.

Фаза 1: Расширение существующего пайплайна (наиболее реалистичный и приоритетный подход)

Цель этой фазы — максимально использовать существующую, хорошо отлаженную архитектуру, добавив в нее новые, перспективные признаки.

- Шаг 1: Генерация и интеграция новых признаков.

1. **Создание синтетических признаков:** Реализовать генерацию синтетических признаков.
2. **Применение нелинейных преобразований:** Создать логарифмические преобразования признаков.
3. **Бинаризация по порогам:** Разработать бинарные признаки на основе порогов.
4. **Интеграция:** Добавить сгенерированные признаки в существующий пайплайн.

- Шаг 2: Перебалансировка весов "голов".

1. После добавления новых признаков старые оптимальные веса ("голов" для модели).
2. **Ключевой момент:** Все эти эксперименты должны оцениваться на OOF-метриках.

- Шаг 3: Тестирование на CC50 и SI.

1. Новые признаки, особенно те, что связаны с физико-химическими свойствами молекул.
2. Можно попробовать добавить наиболее перспективные из них в блоки, отвечающие за извлечение признаков.

Фаза 2: Исследование альтернативных моделей (экспериментальный подход)

Цель этой фазы — проверить, не предлагает ли другой алгоритм машинного обучения лучшую базовую производительность для данной задачи.

- Шаг 1: Замена **CatBoost** на другие градиентные бустинги.

gzNDktZmQ0Yy00MGZkLTgwYzUtYzAzMDk0MzQ4ZTkxIiwicmVzb3VyY2VfaWQiOiJmNzA1NTBmNS1lZGUyLTQyYzAtOGRjMi1jZmUxMDdjNjMxMjAiLCJyZXNvdXJjZV9jaGF0X2lkIjpudWxsQ.6wxB4j6t5m_Xzny9re-3US0kLdq2vHH2bn9TXXh8Z8

2. Molecular Property Prediction Challenge | Kaggle <https://www.kaggle.com/competitions/molecular-property-prediction-challenge>
3. A Broad Intro to Graph Learning & Complex Networks - Kaggle <https://www.kaggle.com/code/hodajalali/a-broad-intro-to-graph-learning-complex-networks>
4. Stanford RNA 3D Folding Competition Insights | Danial A. posted on ... https://www.linkedin.com/posts/danial-ahmed786_machinelearning-kaggle-deeplearning-activity-7445439753036111874-Bs-R
5. A review of machine learning methods for imbalanced data ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC12013631/>
6. Anandharajan TRV's Post - LinkedIn https://www.linkedin.com/posts/anandharajan_kaggle-neurips-cheminformatics-activity-7340562268293644289-862W
7. SMILES DataSet for Analysis & Prediction Dataset - Kaggle <https://www.kaggle.com/datasets/yanmaksi/big-molecules-smiles-dataset>
8. A knowledge-guided pre-training framework for improving molecular ... <https://www.nature.com/articles/s41467-023-43214-1>
9. Open-Source Machine Learning in Computational Chemistry <https://pubs.acs.org/doi/10.1021/acs.jcim.3c00643>
10. Improvement of Prediction Performance With Conjoint Molecular ... <https://www.frontiersin.org/journals/pharmacology/articles/10.3389/fphar.2020.606668/full>
11. A community-powered search of machine learning strategy space to ... <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0253612>
12. Comparative Study of Molecular Descriptors and AI-Based ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC12709611/>
13. Comparative study of machine learning methods for accurate ... <https://www.sciencedirect.com/science/article/pii/S2949747725000181>
14. Molecular Descriptors, Structure Generation, and Inverse QSAR ... <https://pubs.acs.org/doi/10.1021/acsomega.3c01332>
15. BOOM: Benchmarking Out-Of-distribution Molecular Property ... - arXiv <https://arxiv.org/html/2505.01912v1>
16. A systematic study of key elements underlying molecular property ... <https://www.nature.com/articles/s41467-023-41948-6>
17. Tutorial ML In Chemistry Research. RDkit & mol2vec - Kaggle <https://www.kaggle.com/code/vladislavkisin/tutorial-ml-in-chemistry-research-rdkit-mol2vec>

18. An Ensemble Structure and Physicochemical (SPOC) Descriptor for ... <https://chemistry-europe.onlinelibrary.wiley.com/doi/10.1002/cphc.202200255>
19. MoleculeNet: a benchmark for molecular machine learning <https://pubs.rsc.org/en/content/articlehtml/2018/sc/c7sc02664a>
20. The Experimentalist's Guide to Machine Learning for Small Molecule ... <https://pubs.acs.org/doi/10.1021/acsabm.3c00054>
21. Machine Learning Models Identify Inhibitors of SARS-CoV-2 - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC8574161/>
22. SCORCH: Improving structure-based virtual screening with machine ... <https://www.sciencedirect.com/science/article/pii/S2090123222001552>
23. Dealing with the Data | Science | AAAS <https://www.science.org/content/blog-post/dealing-data>
24. Artificial intelligence in antibiotic discovery: Applications, challenges ... [https://www.cell.com/cell-biomaterials/fulltext/S3050-5623\(26\)00101-7](https://www.cell.com/cell-biomaterials/fulltext/S3050-5623(26)00101-7)
25. Impact of Molecular Descriptors on Computational Models https://www.researchgate.net/publication/328337009_Impact_of_Molecular_Descriptors_on_Computational_Models
26. A comprehensive dataset on cytotoxicity of ionic liquids - Nature <https://www.nature.com/articles/s41597-024-04190-3>
27. QSAR-Co-X: an open source toolkit for multitarget QSAR modelling <https://link.springer.com/article/10.1186/s13321-021-00508-0>
28. From library to landscape: integrative annotation workflows for ... <https://academic.oup.com/database/article/doi/10.1093/database/baaf081/8374761>
29. The calculated values of the selectivity index (SI) of some compounds. https://www.researchgate.net/figure/The-calculated-values-of-the-selectivity-index-SI-of-some-compounds_tbl2_349925938
30. Improvement of the Selectivity Index (SI) and Cytotoxicity Activity of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8605847/>
31. SMILES-Based Degree Molecular Descriptors and Machine ... <https://www.frontiersin.org/journals/chemistry/articles/10.3389/fchem.2026.1845927/full>
32. Distribution-based descriptors of the molecular shape - PubMed <https://pubmed.ncbi.nlm.nih.gov/15921456/>
33. The comparison of selectivity index (SI) values of tested compounds ... https://www.researchgate.net/figure/The-comparison-of-selectivity-index-SI-values-of-tested-compounds-SI-was-calculated_fig2_339247352
34. Applications in Coumarin Anti-Cancer Drug Properties - PMC - NIH <https://pmc.ncbi.nlm.nih.gov/articles/PMC11899830/>

35. Comparison of selectivity index (SI) values of the tested compounds.... https://www.researchgate.net/figure/Comparison-of-selectivity-index-SI-values-of-the-tested-compounds-The-SI-Selectivity_fig1_343412606
36. The application of chemical similarity measures in an ... - PMC - NIH <https://pmc.ncbi.nlm.nih.gov/articles/PMC11379871/>
37. Comparison of selectivity index (SI) values of the tested compounds.... https://www.researchgate.net/figure/Comparison-of-selectivity-index-SI-values-of-the-tested-compounds-The-SI-was_fig3_340650265
38. Selectivity Screening and Structure–Cytotoxic Activity Observations ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC11357256/>
39. QSAR Modeling for Predicting IC50 and GI50 Values for Human Cell ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12733303/>
40. A (Comprehensive) Review of the Application of Quantitative ... - MDPI <https://www.mdpi.com/2076-3417/15/3/1206>
41. (PDF) QSAR Models for Predicting Aquatic Toxicity of Esters Using ... https://www.researchgate.net/publication/333885806_QSAR_Models_for_Predicting_Aquatic_Toxicity_of_Esters_Using_Genetic_Algorithm-Multiple_Linear_Regression_Methods_and_Molecular_Descriptors
42. Molecular Descriptors, Structure Generation, and Inverse QSAR ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC10286088/>
43. Nano-(Q)SAR for Cytotoxicity Prediction of Engineered Nanomaterials <https://www.mdpi.com/1420-3049/24/24/4537>
44. Values of significant molecular descriptors for QSAR models (1-3) https://www.researchgate.net/figure/Values-of-significant-molecular-descriptors-for-QSAR-models-1-3_tbl2_340512024
45. Topological polar surface area: A useful descriptor in 2D-QSAR https://www.researchgate.net/publication/23796659_Topological_polar_surface_area_A_useful_descriptor_in_2D-QSAR
46. Topological Polar Surface Area: A Useful Descriptor in 2D-QSAR <https://pmc.ncbi.nlm.nih.gov/articles/PMC7549127/>
47. Parallel Artificial Membrane Permeability Assay (PAMPA) logPm ... https://jeodpp.jrc.ec.europa.eu/ftp/jrc-opendata/EURL-ECVAM/datasets/DBALM/LATEST/online/DBALM_docs/176_M_PAMPA.pdf
48. In vitro and in silico studies of the membrane permeability of natural ... <https://www.sciencedirect.com/science/article/abs/pii/S0944711318302824>
49. Topological Polar Surface Area: A Useful Descriptor in 2D-QSAR https://www.academia.edu/35731471/Topological_Polar_Surface_Area_A_Useful_Descriptor_in_2D_QSAR

50. Exploring the anticancer activities of Sulfur and magnesium oxide ... <https://www.nature.com/articles/s41598-024-82483-8>
51. MAPCliff-WMGR: Exploring Activity Cliffs in Molecular Activity ... <https://pubs.acs.org/doi/10.1021/acs.jcim.5c01915>
52. Scalability and Maintainability Challenges and Solutions in Machine ... <https://arxiv.org/html/2504.11079v1>
53. Interpretable Machine Learning: A Comprehensive Review of ... <https://wires.onlinelibrary.wiley.com/doi/full/10.1002/widm.70075>
54. The future of pharmaceuticals: Artificial intelligence in drug ... <https://www.sciencedirect.com/science/article/pii/S2095177925000656>
55. Integrated QSAR Models for Prediction of Serotonergic Activity - MDPI <https://www.mdpi.com/1999-4923/16/3/349>
56. How to Engineer Features for QSAR Models in Drug Discovery https://www.linkedin.com/posts/pranavi-uppuluri-9b7047228_qsar-ai-ml-activity-7392172435996958721-WR-Q
57. QSAR Classification Models for Predicting the Activity of Inhibitors of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC6591229/>
58. (PDF) A machine learning workflow for molecular analysis https://www.researchgate.net/publication/340725467_A_machine_learning_workflow_for_molecular_analysis_application_to_melting_points
59. Hybridizing Feature Selection and Feature Learning Approaches in ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC5445096/>
60. AI-Integrated QSAR Modeling for Enhanced Drug Discovery - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC12525248/>
61. Descriptors and their selection methods in QSAR analysis - PubMed <https://pubmed.ncbi.nlm.nih.gov/27326911/>
62. Prediction of the Toxicity of Binary Mixtures by QSAR Approach ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC6274693/>
63. QSAR study of phenolic compounds and their anti-DPPH radical ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9098848/>
64. Open Source Bayesian Models. 1. Application to ADME/Tox and ... https://www.researchgate.net/publication/277083086_Open_Source_Bayesian_Models_1_Application_to_ADMETox_and_Drug_Discovery_Datasets
65. Validation of a QSAR model for acute toxicity - PubMed <https://pubmed.ncbi.nlm.nih.gov/16644555/>

66. The role of ligand efficiency metrics in drug discovery | Request PDF https://www.researchgate.net/publication/259988407_The_role_of_ligand_efficiency_metrics_in_drug_discovery
67. QSAR, molecular docking and ADMET properties in silico studies of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8282965/>
68. (PDF) In silico predictive model to determine vector-mediated ... https://www.researchgate.net/publication/265339681_In_silico_predictive_model_to_determine_vector-mediated_transport_properties_for_the_blood-brain_barrier_choline_transporter
69. [PDF] In Silico Methods for Drug Design and Discovery - ResearchGate https://www.researchgate.net/profile/Simone_Brogi/publication/344554590_IN_SILICO_METHODS_FOR_DRUG_DESIGN_AND_DISCOVERY/links/5f8019a7458515b7cf71e173/IN-SILICO-METHODS-FOR-DRUG-DESIGN-AND-DISCOVERY.pdf
70. Eleven quick tips for data cleaning and feature engineering - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC9754225/>
71. Beyond Accuracy: A Modern Framework for Assessing Model ... <https://www.theochemtek.com/posts/beyond-accuracy-a-modern-framework-for-assessing-model-performance-in-molecular-property-prediction>
72. Predicting drug approvals: The Novartis data science and artificial ... <https://www.sciencedirect.com/science/article/pii/S2666389921001550>
73. Prediction of small-molecule compound solubility in organic solvents ... <https://link.springer.com/article/10.1186/s13321-021-00575-3>
74. Benchmarking open-source tools for in silico antiviral drug discovery https://www.researchgate.net/publication/404542629_Benchmarking_open-source_tools_for_in_silico_antiviral_drug_discovery
75. Molecules, Volume 26, Issue 9 (May-1 2021) – 432 articles - MDPI <https://www.mdpi.com/1420-3049/26/9>
76. HPClas: A data – driven approach for identifying halophilic proteins ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC11685839/>
77. Development and Validation of a CatBoost-Based Model for ... - MDPI <https://www.mdpi.com/2673-7426/5/4/71>
78. An Analysis of Model Evaluation with Cross-Validation - ResearchGate https://www.researchgate.net/publication/383955409_An_Analysis_of_Model_Evaluation_with_Cross-Validation_Techniques_Applications_and_Recent_Advances
79. Descriptors and their selection methods in QSAR analysis <https://www.researchgate.net/publication/>

304250663_Descriptors_and_their_selection_methods_in_QSAR_analysis_Paradigm_f
or_drug_design

80. Comparative Analysis of Chemical Descriptors by Machine Learning ... <https://pubs.acs.org/doi/10.1021/acs.molpharmaceut.4c00080>
81. A novel descriptor based on atom-pair properties - Springer Nature <https://link.springer.com/article/10.1186/s13321-016-0187-6>
82. Network pharmacology and molecular dynamics simulation reveal ... <https://www.frontiersin.org/journals/chemistry/articles/10.3389/fchem.2025.1545834/full>
83. Kaggle Molecular Competition: Lessons Learned from Finishing in ... <https://www.linkedin.com/pulse/kaggle-molecular-competition-lessons-learned-from-finishing-nguyen>
84. Molecular Data Machine Learning | Kaggle <https://www.kaggle.com/competitions/molecular-machine-learning>
85. Drug Design Challenge | Kaggle <https://www.kaggle.com/competitions/drug-design-challenge/data>
86. competition_dentu_test | Kaggle <https://kaggle.com/competitions/competition-dentu-test>
87. Kaggle Competitions <https://www.kaggle.com/competitions?searchQuery=health>
88. Predicting Molecular Properties | Kaggle <https://www.kaggle.com/c/champs-scalar-coupling>
89. CIBMTR - Equity in post-HCT Survival Predictions - Kaggle <https://www.kaggle.com/competitions/equity-post-HCT-survival-predictions/discussion/550863>
90. Extreme Condensation | AICC Round 4 - Kaggle <https://www.kaggle.com/competitions/extreme-condensation-aicc-round-4>
91. QSAR Prediction Model to Search for Compounds with Selective ... <https://pubmed.ncbi.nlm.nih.gov/30939759/>
92. Integrated QSAR Models for Prediction of Serotonergic Activity - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC10974160/>
93. QSAR Models for Predicting Oral Bioavailability and Volume of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12565085/>
94. ANN-QSAR, Molecular Docking, ADMET Predictions, and ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC11678770/>
95. A Computational QSAR, Molecular Docking and In Vitro Cytotoxicity ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9570267/>
96. Validation of Quantitative Structure-Activity Relationship (QSAR ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC3257093/>

97. (PDF) Ligand Potency, Efficiency and Drug-likeness - ResearchGate https://www.researchgate.net/publication/333404077_Ligand_Potency_Efficiency_and_Drug-likeness_A_Story_of_Intuition_Misinterpretation_and_Serendipity
98. [PDF] 2017 FDA Science Forum <https://www.fda.gov/files/science%20&%20research/published/2017-FDA-Science-Forum-Brochure.pdf>
99. DEL Hunter - HitGen OpenDEL™ <https://www.opendelcommunity.com/delhunter/>
100. Big-Data Science in Porous Materials - ACS Publications <https://pubs.acs.org/doi/10.1021/acs.chemrev.0c00004>
101. Machine learning in antiviral drug design - ScienceDirect.com <https://www.sciencedirect.com/science/article/pii/S0968089625003670>
102. converting SMILES to a drug vector for predicting the activity of anti ... <https://academic.oup.com/bib/article-pdf/doi/10.1093/bib/bbab593/42805068/bbab593.pdf>
103. Artificial Intelligence Technologies for COVID-19 De Novo Drug ... <https://www.mdpi.com/1422-0067/23/6/3261>
104. Antiviral drug discovery and development: challenges and future ... <https://www.nature.com/articles/s41392-025-02539-7>
105. Best Practices for Small Datasets - Kaggle <https://www.kaggle.com/questions-and-answers/575548>
106. Benchmarking ML in ADMET predictions: the practical impact of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12281724/>
107. Multifunctional polyimide performance prediction based on ... <https://onlinelibrary.wiley.com/doi/full/10.1002/smo2.70020>
108. Data-driven viscosity prediction in hydroxyapatite/graphene inks for ... <https://www.sciencedirect.com/science/article/pii/S2949822826006234>
109. Deciphering Molecular and Solvent Effects on Aqueous and Organic ... <https://pubs.acs.org/doi/10.1021/acsomega.5c13630>
110. QSAR, Molecular Docking, MD Simulation and MMGBSA ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC9370430/>
111. QSAR, molecular docking and ADMET properties in silico studies of ... <https://www.sciencedirect.com/science/article/pii/S2405844021015668>
112. ProQSAR: A modular and reproducible framework for small-data ... <https://link.springer.com/article/10.1186/s13321-026-01175-9>
113. (PDF) alvaDesc: A Tool to Calculate and Analyze Molecular ... https://www.researchgate.net/publication/338635534_alvaDesc_A_Tool_to_Calculate_and_Analyze_Molecular_Descriptors_and_Fingerprints

114. Monte Carlo Method and GA-MLR-Based QSAR Modeling of NS5A ... <https://www.mdpi.com/1420-3049/27/9/2729>
115. [PDF] QUANTITATIVE STRUCTURE-ACTIVITY RELATIONSHIP (QSAR ... <http://ajates-scholarly.com/index.php/ajates/article/download/47/43>
116. Development and validation of PAMPA-BBB QSAR model to predict ... <https://www.frontiersin.org/journals/pharmacology/articles/10.3389/fphar.2023.1291246/full>
117. (PDF) ProTox-II: A webserver for the prediction of toxicity of chemicals https://www.researchgate.net/publication/324889937_ProTox-II_A_webserver_for_the_prediction_of_toxicity_of_chemicals
118. Viruses, Volume 17, Issue 7 (July 2025) – 153 articles <https://www.mdpi.com/1999-4915/17/7>
119. Abstracts of the papers presented in the international conference of ... <https://link.springer.com/article/10.1007/s13337-025-00913-1>
120. RDKit Feature Engineering with Hill Climbing and Multi Model ... <https://www.kaggle.com/competitions/melting-point/discussion/690519>
121. Kaggle Winning Solutions: AI Trends & Insights <https://www.kaggle.com/code/tahaalselwii/kaggle-winning-solutions-ai-trends-insights>
122. (PDF) Kaggle LSHTC4 Winning Solution - ResearchGate https://www.researchgate.net/publication/262071016_Kaggle_LSHTC4_Winning_Solution
123. senkin13 | Kaggle <https://www.kaggle.com/senkin13/discussion>
124. 50th Place Solution | Kaggle <https://www.kaggle.com/competitions/uspto-explainable-ai/writeups/filtered-50th-place-solution>
125. 2nd place solution --- Avoid leaks and overfitting - Kaggle <https://www.kaggle.com/competitions/playground-series-s6e2/writeups/2nd-place-solution-avoid-leaks-and-overfitting>
126. Giba | Kaggle <https://www.kaggle.com/titericz/writeups>
127. 5th place solution - Kaggle <https://www.kaggle.com/competitions/bengaliai-cv19/writeups/team-dieter-5th-place-solution>
128. [PDF] Virtual-screening workflow tutorials and ... - F1000Research <https://f1000research.com/articles/6-1136/pdf>
129. 5th Place Solution — msa and protenix and TBM - Kaggle <https://www.kaggle.com/competitions/stanford-rna-3d-folding-2/writeups/5th-place-solution-stanford-rna-3d-folding-part>
130. Benchmarking deep learning models for predicting anticancer drug ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12957364/>

131. Benchmarking Deep Learning Models for Predicting Anticancer ... https://www.researchgate.net/publication/393696552_Benchmarking_Deep_Learning_Models_for_Predicting_Anticancer_Drug_Potency_IC50_Insights_for_the_Medicinal_Chemist
132. Prediction of Anti-Glioblastoma Drug-Decorated Nanoparticle ... <https://www.mdpi.com/1422-0067/22/21/11519>
133. Machine learning driven LD50 prediction for cancer risk ... - Frontiers <https://www.frontiersin.org/journals/oncology/articles/10.3389/fonc.2026.1788240/full>
134. A multi-task learning approach for prediction of missing bioactivity ... <https://pubs.rsc.org/en/content/articlelanding/2026/dd/d5dd00536a>
135. [PDF] A Simple Machine Learning-Based Quantitative Structure–Activity ... <https://pdfs.semanticscholar.org/a40e/7ea1c4c034472ad8afbb74971056107e4314.pdf>
136. Pat Walters' Post - LinkedIn https://www.linkedin.com/posts/wpwalters_as-readers-of-practical-cheminformatics-know-activity-7132794338022969345-Q2Vi
137. A paradigmatic approach to the molecular descriptor computation for ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC10658280/>
138. On Various Metrics Used for Validation of Predictive QSAR Models ... https://www.researchgate.net/publication/51077999_On_Various_Metrics_Used_for_Validation_of_Predictive_QSAR_Models_with_Applications_in_Virtual_Screening_and_Focused_Library_Design
139. On various metrics used for validation of predictive QSAR models ... <https://pubmed.ncbi.nlm.nih.gov/21521150/>
140. New QSAR Models to Predict Human Transthyretin Disruption by Per <https://pmc.ncbi.nlm.nih.gov/articles/PMC12300718/>
141. Integration of QSAR and SAR methods for the mechanistic ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC3962111/>
142. Mechanistic-based Descriptors for QSAR Study of Psychotropic ... <https://pubmed.ncbi.nlm.nih.gov/19012576/>
143. Mechanistic and Predictive QSAR Analysis of Diverse Molecules to ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8348508/>
144. Quantitative Structure-Activity Relationship (QSAR) Studies on the ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8395302/>
145. QSAR model for mutagenicity of nitroaromatic compounds - PubMed <https://pubmed.ncbi.nlm.nih.gov/39207617/>
146. Utilizing Molecular Descriptor Importance to Enhance Endpoint ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12115611/>

147. Artificial intelligence in antibiotic discovery: Applications, challenges ... <https://www.sciencedirect.com/science/article/pii/S3050562326001017>
148. RoSHAP: A Distributional Framework and Robust Metric for Stable ... <https://arxiv.org/html/2605.15154v1>
149. A data-driven framework for predicting external corrosion rates of ... <https://www.sciencedirect.com/science/article/pii/S2667143326001058>
150. Benchmarking AutoML for regression tasks on small tabular data in ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9652348/>
151. Comparative Analysis of Machine Learning Models for Predicting ... <https://www.mdpi.com/2076-3417/15/7/3636>
152. Small data machine learning in materials science - Nature <https://www.nature.com/articles/s41524-023-01000-z>
153. Model Evaluation, Model Selection, and Algorithm Selection in ... https://www.researchgate.net/publication/329362431_Model_Evaluation_Model_Selection_and_Algorithm_Selection_in_Machine_Learning
154. [PDF] Prediction of obesity levels based on physical activity and ... - Frontiers <https://www.frontiersin.org/journals/physiology/articles/10.3389/fphys.2025.1549306/pdf>
155. Recognizing the power of machine learning and other ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC10019373/>
156. Quantitative Structure-Activity Relationship - ScienceDirect.com <https://www.sciencedirect.com/topics/physics-and-astronomy/quantitative-structure-activity-relationship>
157. Accurate prediction of K_{p,uu}, brain based on experimental ... [https://www.cell.com/heliyon/fulltext/S2405-8440\(24\)00335-9](https://www.cell.com/heliyon/fulltext/S2405-8440(24)00335-9)
158. Orthogonal Molecular Feature Signatures Guide Multi-Target ... - MDPI <https://www.mdpi.com/3042-4518/3/2/19>
159. Exploring chemical space for “druglike” small molecules in the age ... <https://www.frontiersin.org/journals/molecular-biosciences/articles/10.3389/fmolb.2025.1553667/full>
160. (PDF) Mordred: A molecular descriptor calculator - ResearchGate https://www.researchgate.net/publication/322967296_Mordred_A_molecular_descriptor_calculator
161. A review of methods for the calculation of solution free energies and ... <https://pubs.rsc.org/en/content/articlehtml/2015/cp/c5cp00288e>
162. Prediction of Acute Mammalian Toxicity Using QSAR Methods - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC6269063/>

163. On the Development and Validation of QSAR Models - ResearchGate https://www.researchgate.net/publication/232534576_On_the_Development_and_Validation_of_QSAR_Models
164. High-Dimensional Descriptor Selection and Computational QSAR ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC3269744/>
165. Machine learning-guided Nano-QSAR modeling predicts HepaRG ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12894165/>
166. (PDF) Permutation importance: A corrected feature ... - ResearchGate https://www.researchgate.net/publication/43130914_Permutation_importance_A_corrected_feature_importance_measure
167. Evaluation of prediction models for slope stability on road cut slopes ... <https://www.sciencedirect.com/science/article/pii/S1226798825004945>
168. Machine Learning for Sensor Analytics: A Comprehensive Review ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12694449/>
169. Prediction model for additional procedure requirement in flexible ... <https://www.nature.com/articles/s41598-026-46898-9>
170. The Attribution Impossibility: No Feature Ranking Is Faithful, Stable ... <https://arxiv.org/html/2605.21492v1>
171. The Use of Machine Learning in Aluminum and Magnesium Matrix ... <https://link.springer.com/article/10.1007/s11831-026-10511-z>
172. Full article: A Real-Time Plasma Concentration Prediction Model for ... <https://www.tandfonline.com/doi/full/10.2147/DDDT.S495050>
173. Molecules, Volume 27, Issue 3 (February-1 2022) – 567 articles <https://www.mdpi.com/1420-3049/27/3>
174. Open Source Bayesian Models. 1. Application to ADME/Tox and ... <https://pubs.acs.org/doi/10.1021/acs.jcim.5b00143>
175. a web server for cavity detection-guided protein–ligand blind docking https://www.researchgate.net/publication/334149403_CB-Dock_a_web_server_for_cavity_detection-guided_protein-ligand_blind_docking
176. Molecules, Volume 28, Issue 4 (February-2 2023) – 484 articles <https://www.mdpi.com/1420-3049/28/4>
177. Synthesis, Characterization, In Silico DFT, Molecular Docking, and ... <https://pubs.acs.org/doi/10.1021/acsomega.4c00079>
178. DNA-Encoded Chemical Libraries: A Comprehensive Review with ... <https://pubs.acs.org/doi/10.1021/acscptsci.1c00118>
179. Combining Machine Learning and Molecular Dynamics to Predict P ... <https://pubs.acs.org/doi/10.1021/acs.jcim.0c00525>

180. The Brain Exposure Efficiency (BEE) Score - ACS Publications <https://pubs.acs.org/doi/10.1021/acscemneuro.9b00650>
181. ADMET Evaluation in Drug Discovery. 18. Reliable Prediction of ... <https://pubs.acs.org/doi/10.1021/acs.molpharmaceut.7b00631>
182. DrugSensitivity 2 - Kaggle <https://www.kaggle.com/c/drugsensitivity-2/data>
183. Baseline - RDKit descriptors features - Kaggle <https://www.kaggle.com/code/senkin13/baseline-rdkit-descriptors-features>
184. Quercetin IC50 and CC50. (A) IC50 of quercetin inhibition of... https://www.researchgate.net/figure/Quercetin-IC50-and-CC50-A-IC50-of-quercetin-inhibition-of-synctialization-of_fig3_377698965
185. Benchmarking deep learning models for predicting anticancer drug ... <https://www.nature.com/articles/s42004-026-01916-9>
186. Improving the accuracy of prediction models for small datasets of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12044814/>
187. A Feature Importance-Based Multi-Layer CatBoost for Student ... https://www.researchgate.net/publication/380340191_A_Feature_Importance-Based_Multi-Layer_CatBoost_for_Student_Performance_Prediction
188. CatBoost Baseline with Feature Importance - Kaggle <https://www.kaggle.com/code/gogo827jz/catboost-baseline-with-feature-importance>
189. 5.2. Permutation feature importance - Scikit-learn https://scikit-learn.org/stable/modules/permutation_importance.html
190. Drastically different feature importance between very same data and ... <https://stackoverflow.com/questions/52088064/drastically-different-feature-importance-between-very-same-data-and-very-similar>
191. Robust Prediction of Compressive Strength of SCM Concrete with ... <https://www.mdpi.com/1999-4893/19/4/277>
192. AI-powered IC50 prediction for p53 inhibitors drug-target interaction ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12738643/>
193. Mechanisms of Action (MoA) Prediction | Kaggle <https://www.kaggle.com/competitions/lish-moa>
194. Deep Multitask Learning-Driven Discovery of New Compounds ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC11696749/>
195. Clustering Protein Binding Pockets and Identifying Potential Drug ... <https://pubs.acs.org/doi/10.1021/acs.jcim.3c00722>
196. Ultralarge Virtual Screening Identifies SARS-CoV-2 Main Protease ... <https://pubs.acs.org/doi/10.1021/jacs.1c08402>

197. QSAR study of unsymmetrical aromatic disulfides as potent avian ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC7857023/>
198. Predictive Modeling of Chemical Hazard by Integrating Numerical ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC3327873/>
199. Development and interpretation of a QSAR model for in vitro breast ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8093599/>
200. Quantitative structure–activity relationship-based computational ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9300454/>
201. Predicting Chemical Immunotoxicity through Data-Driven QSAR ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC11264268/>
202. High predictive QSAR models for predicting the SARS coronavirus ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8547569/>
203. An evaluation of the performance of selected (Q)SARs/expert ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC7641510/>
204. In silico ADME/T modelling for rational drug design <https://www.cambridge.org/core/journals/quarterly-reviews-of-biophysics/article/in-silico-admet-modelling-for-rational-drug-design/967D13A3BF04B9B46B692472CF800A74>
205. Molecules, Volume 26, Issue 23 (December-1 2021) – 350 articles <https://www.mdpi.com/1420-3049/26/23>
206. Computational toxicology in drug discovery: applications of artificial ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12499773/>
207. Project 3 - Data Science Skills - RPubS <https://www.rpubs.com/crummettsam/1288039>
208. Quantum Machine Learning for Drug Discovery - ACM Digital Library <https://dl.acm.org/doi/10.1145/3785660>
209. Article Machine learning prediction of glass transition temperature of ... <https://www.sciencedirect.com/science/article/pii/S2666386422001898>
210. Recent applications of deep learning and machine intelligence on in ... <https://academic.oup.com/bib/article/20/5/1878/5062947>
211. Detecting hallucinations in large language models using semantic ... <https://www.nature.com/articles/s41586-024-07421-0>
212. Prediction of Anti-Glioblastoma Drug-Decorated Nanoparticle ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC8584266/>
213. i-DENV: development of QSAR based regression models for ... <https://www.frontiersin.org/journals/pharmacology/articles/10.3389/fphar.2025.1605722/full>

214. [PDF] SG-ATT: A Sequence Graph Cross-Attention Representation ... <https://pdfs.semanticscholar.org/bd49/8eda1a23cd7b178a937e98fd354a13a8e0e5.pdf>
215. SG-ATT: A Sequence Graph Cross-Attention Representation ... - MDPI <https://www.mdpi.com/1420-3049/29/2/492>
216. CHEMIF.PTML Lab Newsletter 03 ed., TOXIF.PTML models in ... <https://www.linkedin.com/pulse/ifptml-models-toxicology-ecotoxicology-environmental-g-d%C3%ADaz-prof--3bmaf>
217. QSAR analysis on a large and diverse set of potent ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC9005662/>
218. Experimental vs. predictive values expressed in – log (IC50)A549 ... https://www.researchgate.net/figure/Experimental-vs-predictive-values-expressed-in-log-IC50A549-of-the-QSAR-models-by-MLR_fig4_342704118
219. Comparison of Quantitative and Qualitative (Q)SAR Models Created ... <https://www.frontiersin.org/journals/pharmacology/articles/10.3389/fphar.2018.01136/full>
220. QSAR based virtual screening derived identification of a novel hit as ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8524701/>
221. nestedcv: an R package for fast implementation of nested cross ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC10125905/>
222. An Application in Age Prediction Using Brain Complexity Features <https://www.mdpi.com/2076-3417/12/13/6681>
223. ARTICLE IN PRESS - Nature https://www.nature.com/articles/s41598-026-48176-0_reference.pdf
224. Catboost Pipeline +Nested crossvalidation + Optuna | Kaggle <https://www.kaggle.com/code/raphael2711/catboost-pipeline-nested-crossvalidation-optuna>
225. Biomedicines, Volume 14, Issue 1 (January 2026) – 256 articles <https://www.mdpi.com/2227-9059/14/1>